https://hjfy.top/arxiv/1702.05464

对抗性判别领域自适应

Eric Tzeng
University of California, Berkeley
etzeng@eecs.berkeley.edu

Judy Hoffman
Stanford University
jhoffman@cs.stanford.edu

Kate Saenko
Boston University
saenko@bu.edu

Trevor Darrell
University of California, Berkeley
trevor@eecs.berkeley.edu

Abstract

对抗学习方法是一种有前景的训练鲁棒深度网络的方法，能够生成跨多样化领域的复杂样本。它们还能在存在领域偏移或数据集偏差的情况下提升识别性能：最近已提出多种无监督领域自适应的对抗方法，这些方法减少了训练域与测试域分布之间的差异，从而提升了泛化性能。先前的生成方法展现出引人注目的可视化效果，但在判别任务上并非最优，且仅适用于较小的领域偏移。先前的判别方法虽能处理更大的领域偏移，但对模型施加了捆绑权重限制，并未利用基于 *GAN* 的损失函数。我们首先概述了一个新颖的对抗自适应通用框架，该框架将近期最先进的方法作为特例包含在内，并利用这一通用视角更好地关联先前的方法。我们提出了一种此前未被探索的通用框架实例，该实例结合了判别建模、非绑定权共享以及 *GAN* 损失，称为对抗判别领域自适应（*ADDA*）。我们证明，*ADDA* 相较于现有的领域对抗方法更为有效且显著更简单，并通过在标准跨领域数字分类任务和一项更具挑战性的跨模态物体分类任务上超越当前最先进无监督自适应结果，展示了我们方法的潜力。

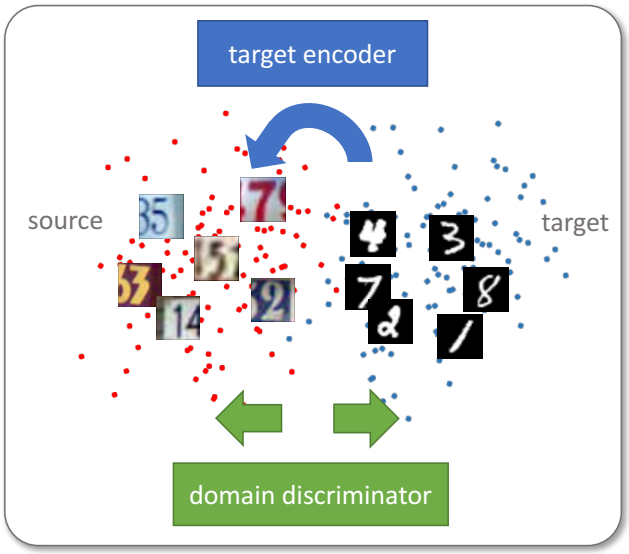

图 1: 我们提出了一种改进的无监督领域自适应方法，该方法结合了对抗学习与判别特征学习。具体而言，我们通过欺骗试图区分编码后的目标图像与源域样本的领域判别器，学习将目标图像映射到源域特征空间的判别性映射（目标编码器）。

1. 引言

深度卷积网络在大规模数据集上训练后，可以学习到在多种任务和视觉领域中普遍有用的表示 [1, 2]。然而，由于一种被称为 *数据集偏差* 或 *领域偏移* 的现象 [3]，仅在单一大规模数据集上与这些表示一起训练的识别模型在新数据集和任务上的泛化能力较差 [4, 1]。典型解决方案是将这些网络在特定任务的数据集上进

一步微调——但通常难以且代价高昂地获取足够多的标注数据，以正确微调深度多层网络所使用的大量参数。

领域自适应方法旨在缓解领域偏移带来的不利影响。最近的领域自适应方法学习深度神经变换，将两个领域映射到一个共同的特征空间中。这通常通过优化表示以最小化某种领域偏移度量（如最大平均偏差 [5, 6] 或相关系数距离 [7, 8]）来实现。另一种方法是利用源表示重构目标领域 [9]。

对抗自适应方法已成为此类方法的一种日益流行的形式，其目标是通过相对于领域判别器的对抗目标来最小化近似的领域差异距离。这些方法与生成对抗学习 [10] 密切相关，后者将两个网络置于相互对抗的关系中——一个生成器和一个判别器。生成器被训练以生成能够迷惑判别器的图像，而判别器则试图将这些图像与真实的图像样本区分开来。在领域自适应中，这一原理被用于确保网络无法区分其训练域和测试域样本的分布 [11, 12, 13]。然而，每种算法在设计上有所不同，例如是否使用生成器、采用何种损失函数，或是否在不同领域间共享权重。例如， [11, 12] 共享权重并学习源域和目标域图像到共享特征空间的对称映射，而 [13] 则解耦部分层，从而学习一种部分非对称的映射。

在本工作中，我们提出了一种新颖的统一框架，用于对抗性领域自适应，使我们能够有效分析现有方法之间变差因素的差异，并清晰地观察它们各自所共有的相似之处。我们的框架统一了权重共享、基础模型和对抗损失等设计选择，涵盖了先前的工作，同时也有助于设计出优于现有方法的新实例。

特别地，我们观察到，对输入图像分布进行生成式建模并非必要，因为最终任务是学习一种判别式表示。另一方面，非对称映射比对称映射能更好地建模低层特征的差异。因此，我们提出了一种此前未被探索的无监督对抗领域自适应方法——对抗判别领域自适应（ADDA），如图 1所示。ADDA 首先利用源领域的标签学习一种判别式表示，然后通过一个通过领域对抗损失学习得到的非对称映射，学习一个独立的编码，将目标数据映射到相同的表示空间。我们的方法简单却出人意料地强大，在 MNIST、USPS 和 SVHN 数字数据集上实现了当前最优的视觉领域自适应效果。我们还测试了其在无需实例约束的情况下，弥合更具挑战性的跨模态迁移差距的潜力，例如将基于 RGB 彩色图像的物体分类器迁移到深度观测数据中。

2. 相关工作

在领域迁移学习方面已有大量先验研究，参见例如 [3]。近期工作主要集中在将标注源数据集中的深度神经网络表示迁移到标签数据稀疏或不存在的目标领域。在未标记目标领域的情况下（本文的重点），主要策略是通过最小化源域与目标域特征分布之间的差异来引导特征学习 [11, 12, 5, 6, 8, 9, 13]。

几种方法使用了最大平均偏差（Maximum Mean Discrepancy, MMD） [3] 损失来实现这一目标。MMD 计算两个领域均值之差的范数。DDC 方法 [5] 在源领域的常规分类损失基础上额外使用了 MMD，以学习一种既具有判别性又在领域间不变的表示。深度适应网络（Deep Adaptation Network, DAN） [6] 将 MMD 应用于嵌入再生核希尔伯特空间的层，有效地匹配了两个分布的高阶统计量。相比之下，深度相关性对齐（Deep Correlation Alignment, CORAL） [8] 方法提出通过匹配两个分布的均值和协方差来实现对齐。

其他方法选择了对抗损失来最小化领域偏移，学习一种同时对源标签具有区分性但无法区分领域的表示。[12] 提出添加一个领域分类器（一个全连接层），用于预测输入的二分类领域标签，并设计了领域混淆损失，以促使该分类器的预测尽可能接近二分类标签的均匀分布。在 [11]中提出的梯度反转算法（ReverseGrad）也将领域不变性视为一个二分类问题，但通过反转其梯度来直接最大化领域分类器的损失。DRCN [9]采用了类似的方法，同时还学习重建目标领域的图像。

In related work, adversarial learning has been explored for generative tasks. The Generative Adversarial Network (GAN) method [10] is a generative deep model that pits two networks against one another: a generative model G that captures the data distribution and a discriminative model D that distinguishes between samples drawn from G and images drawn from the training data by predicting a binary label. The networks are trained jointly using backprop on the label prediction loss in a mini-max fashion: simultaneously update G to minimize the loss while also updating D to maximize the loss (fooling the discriminator). The ad-

vantage of GAN over other generative methods is that there is no need for complex sampling or inference during training; the downside is that it may be difficult to train. GANs have been applied to generate natural images of objects, such as digits and faces, and have been extended in several ways. The BiGAN approach [14] extends GANs to also learn the inverse mapping from the image data back into the latent space, and shows that this can learn features useful for image classification tasks. The conditional generative adversarial net (CGAN) [15] is an extension of the GAN where both networks G and D receive an additional vector of information as input. This might contain, say, information about the class of the training example. The authors apply CGAN to generate a (possibly multi-modal) distribution of tag-vectors conditional on image features.

最近，CoGAN [13] 方法通过训练两个 GAN 分别生成源域和目标域图像，将 GAN 应用于领域迁移问题。该方法通过绑定两个 GAN 的高层层参数，实现了领域不变的特征空间，并表明相同的噪声输入可以分别从两个分布中生成对应的一对图像。领域自适应通过在判别器输出上训练分类器来实现，并应用于 MNIST 与 USPS 数字数据集之间的分布偏移。然而，该方法依赖于生成器在两个领域中均能从共享的高层特征空间映射到完整图像。对于数字这类任务效果较好，但在领域差异较大的情况下可能难以奏效。本文观察到，只要潜在特征空间是领域不变的，建模图像分布并非实现领域自适应的必要条件，因此我们提出一种判别方法。

3. 泛化对抗适应

我们提出了一种面向对抗无监督领域自适应方法的通用框架。在无监督自适应中，我们假设可以获取从源领域分布 $p_s(x,y)$ 中采样得到的源图像 $\mathbf{X}_s$ 与标签 Y_s，以及从目标分布 $p_t(x,y)$ 中采样得到的目标图像 $\mathbf{X}_t$，且目标域无标签标注。

我们的目标是学习一个目标表示 M_t 与分类器 C_t，使其能够在测试阶段将目标图像正确分类为 K 个类别之一，即便目标域缺乏领域内标注。

由于无法直接在目标域上开展监督学习，领域自适应转而先学习源表示映射 M_s 与源分类器 C_s，随后学习将该模型适配至目标域以用于目标域任务。

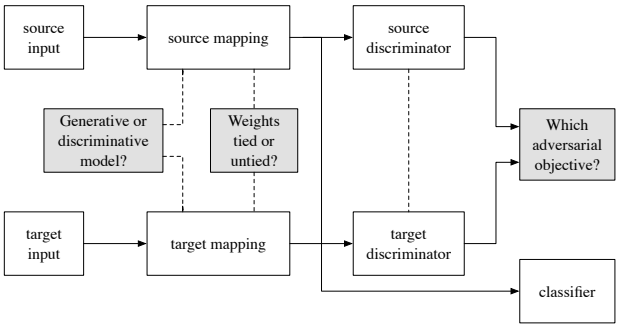

图 2: 我们针对对抗领域自适应的泛化架构。现有的对抗自适应方法可被视为该框架在不同属性选择下的具体实例。

在对抗自适应方法中，主要目标是正则化源域和目标域映射 M_s 和 M_t 的学习，以最小化经验源映射分布 $M_s(X_s)$ 与目标映射分布 $M_t(X_t)$ 之间的距离。如果是这种情况，则可以将源分类模型 C_s 直接应用于目标表示，从而消除学习独立目标分类器的需要，而是设定 $C = C_s = C_t$ 。

然后使用下面的标准监督损失对源分类模型进行训练：

$$\min_{M_s,C} \mathcal{L}_{\text{cls}}(\mathbf{X}_s, Y_t) = \mathbb{E}_{(\mathbf{x}_s,y_s)\sim(\mathbf{X}_s,Y_t)} -\sum_{k=1}^{K} \mathbb{1}_{[k=y_s]} \log C(M_s(\mathbf{x}_s)) \quad (1)$$

我们现在能够描述对抗适应方法的完整通用框架视图。我们注意到，所有方法都通过在两个函数之间交替最小化源域和目标域表示距离来实现。首先是一个领域判别器 D，它用于判断一个数据点是否来自源域或目标域。因此，D 根据标准监督损失 $\mathcal{L}_{\text{adv}_D}(\mathbf{X}_s, \mathbf{X}_t, M_s, M_t)$ 进行优化，其中标签表示数据点的来源领域，定义如下：

$$\begin{aligned}\mathcal{L}_{\text{adv}_D}(\mathbf{X}_s, \mathbf{X}_t, M_s, M_t) = \\ -\mathbb{E}_{\mathbf{x}_s\sim\mathbf{X}_s}[\log D(M_s(\mathbf{x}_s))] \\ -\mathbb{E}_{\mathbf{x}_t\sim\mathbf{X}_t}[\log(1 - D(M_t(\mathbf{x}_t)))]\end{aligned} \quad (2)$$

其次，源域和目标域的映射根据一个受约束的对抗性目标进行优化，该目标的具体实现方式可能因方法而异。因此，我们可以得出领域对抗技术的一个通用公式

Method	Base model	Weight sharing	Adversarial loss
Gradient reversal [16]	discriminative	shared	minimax
Domain confusion [12]	discriminative	shared	confusion
CoGAN [13]	generative	unshared	GAN
ADDA (Ours)	discriminative	unshared	GAN

表 1: 对抗领域自适应方法及其各种特性的概述。在统一框架下审视这些方法，使我们能够轻松提出一种新的自适应方法——对抗判别式领域自适应（ADDA）。

如下：

$$\begin{aligned} &\min_{D} \ \mathcal{L}_{\text{adv}_D}(\mathbf{X}_s, \mathbf{X}_t, M_s, M_t) \\ &\min_{M_s, M_t} \ \mathcal{L}_{\text{adv}_M}(\mathbf{X}_s, \mathbf{X}_t, D) \\ &\text{s.t.} \quad \psi(M_s, M_t) \end{aligned} \tag{3}$$

在接下来的章节中，我们通过将近期的领域对抗方法置于我们的框架内，展示了该框架的价值。我们描述了潜在的映射结构、映射最优化约束（$\psi(M_s, M_t)$）的选择，以及最终对抗映射损失 $\mathcal{L}_{\text{adv}_M}$ 的选择。

3.1. 源和目标映射

在仅学习源域映射 M_s 的情况下，显然通过使用已知标签 Y_s 的潜在空间判别损失进行监督训练，能够得到最优的源域识别表示。然而，由于我们的目标领域是未标记的，如何最好地最小化源域与目标域映射之间的距离仍是一个开放问题。因此，首要决策在于这些映射的具体参数化方式。

由于无监督领域自适应通常考虑目标判别任务，如分类，因此以往的自适应方法普遍依赖于在领域间对判别模型进行适应 [12, 16]。采用判别式基础模型时，输入图像被映射到一个对判别任务（如图像分类）有用的特征空间。例如，在数字分类的情况下，这可能是标准的 LeNet 模型。然而，Liu 和 Tuzel 在无监督 MNIST-USPS 任务上通过使用两个生成对抗网络取得了当前最优结果 [13]。这些生成式模型以噪声作为输入，在图像空间中生成样本——通常会使用对抗判别器的中间特征作为训练特定任务分类器的特征。

一旦确定了源域的映射参数化，我们就必须决定如何对目标映射 M_t 进行参数化。一般来说，目标映射在具体的函数层（架构）上几乎总是与源域保持一致，但不同方法提出了各种正则化技术。所有方法都使用源域初始化目标映射参数，但不同方法在源域与目标映射之间选择了不同的约束，$\psi(M_s, M_t)$。目标是确保目标映射被设定为在各自映射下最小化源域与目标域之间的距离，同时关键地保持目标映射具有类别判别性。

考虑一种分层表示，其中每一层的参数记为 M_s^ℓ 或 M_t^ℓ ，对于给定的一组等价层，$\{\ell_1, \ldots, \ell_n\}$ 。然后，文献中探索的约束空间可以通过如下分层等式约束来描述：

$$\psi(M_s, M_t) \triangleq \{\psi_{\ell_i}(M_s^{\ell_i}, M_t^{\ell_i})\}_{i \in \{1 \ldots n\}} \tag{4}$$

其中每一层都可以独立地受到约束。一种非常常见的约束形式是源层与目标层之间的逐层相等：

$$\psi_{\ell_i}(M_s^{\ell_i}, M_t^{\ell_i}) = (M_s^{\ell_i} = M_t^{\ell_i}). \tag{5}$$

在层上不加约束也很常见。这些等式约束可以通过权共享在卷积网络框架中轻松实现。

对于许多先验对抗适应方法 [16, 12]，所有层都受到约束，从而强制实现源领域和目标领域映射的一致性。学习一个对称变换可以减少模型中的参数数量，并确保在应用于源领域时，用于目标领域的映射具有判别性。然而，这可能会导致最优化条件不佳，因为同一个网络必须处理来自两个分离领域图像。

另一种方法是学习一种非对称变换，仅约束部分层，从而强制实现部分对齐。Rozantsev 等人 [17] 证明，部分共享权重可以在监督和无监督情景下均实现有效的适应。因此，一些近期的方法更倾向于在两个领域之间解耦权重（完全或部分），使模型能够为每个领域分别学习参数。

3.2. 对抗损失

一旦我们确定了对 M_t 的参数化方式，便采用对抗损失来学习实际的映射关系。对抗损失函数有多种

不同的可选形式，每种都有其独特的应用场景。所有对抗损失均使用标准分类损失 $\mathcal{L}_{\text{adv}_D}$ 来训练对抗判别器，该损失函数已在公式 2 中给出。然而，它们在用于训练映射 $\mathcal{L}_{\text{adv}_M}$ 时所使用的损失上有所不同。

[16] 的梯度反转层直接优化映射以最大化判别器损失：

$$\mathcal{L}_{\text{adv}_M} = -\mathcal{L}_{\text{adv}_D}. \tag{6}$$

这种最优化对应生成对抗网络的真实极小极大目标。然而，该目标可能存在问题，因为在训练初期，判别器会迅速收敛，导致梯度消失。

训练生成对抗网络（GAN）时，通常不会直接使用极小极大损失，而是使用标准损失函数并反转标签来训练生成器 [10]。这将最优化过程分解为两个独立的目标，一个用于生成器，另一个用于判别器，其中 $\mathcal{L}_{\text{adv}_D}$ 保持不变，但 $\mathcal{L}_{\text{adv}_M}$ 变为：

$$\mathcal{L}_{\text{adv}_M}(\mathbf{X}_s, \mathbf{X}_t, D) = -\mathbb{E}_{\mathbf{x}_t \sim \mathbf{X}_t}[\log D(M_t(\mathbf{x}_t))]. \tag{7}$$

该目标函数具有与极小极大损失相同的固定点性质，但为目标映射提供了更强的梯度。在本文余下部分，我们将此修改后的损失函数称为“GAN 损失函数”。

请注意，在此情景中，我们对源域和目标域使用独立的映射，并且仅学成 M_t 对抗性。这模拟了生成对抗网络（GAN）的情景，其中真实图像分布保持固定，而生成分布则被学习以匹配它。

生成对抗网络的损失函数在生成器试图模仿另一个不变分布的情景中是标准选择。然而，在两个分布均在变化的情景中，此目标会导致振荡——当映射收敛到其最优解时，判别器只需反转其预测符号即可作出响应。Tzeng 等人则提出了领域混淆目标，该目标下映射使用交叉熵损失函数与均匀分布进行训练 [12]:

$$\begin{aligned}\mathcal{L}_{\text{adv}_M}(\mathbf{X}_s, \mathbf{X}_t, D) = \\ -\sum_{d \in \{s,t\}} \mathbb{E}_{\mathbf{x}_d \sim \mathbf{X}_d} \Big[\frac{1}{2} \log D(M_d(\mathbf{x}_d)) \\ + \frac{1}{2} \log(1 - D(M_d(\mathbf{x}_d))) \Big].\end{aligned} \tag{8}$$

该损失确保对抗判别器将两个领域视为相同。

4. 对抗性判别领域自适应

我们对领域对抗方法的泛化框架的优势在于，它直接促进了新型自适应方法的开发。事实上，设计一种新方法现在已简化为三个设计选择的空间：是否使用生成式或判别式基础模型，是否共享权重或不共享权重，以及采用哪种对抗学习目标。基于这一视角，我们可以根据我们的选择总结出本方法——对抗判别式领域自适应（ADDA）及其与先前工作的联系（见表 1 “ADDA”）。具体而言，我们采用判别式基础模型、非共享权重，并使用标准 GAN 损失。我们在图 3中展示了整体的顺序训练流程。

首先，我们选择一个判别式基础模型，因为我们假设生成领域内逼真样本所需的大部分参数对于判别式适应任务来说是无关的。大多数先前的对抗适应方法出于这一原因直接在判别空间中进行优化。一个反例是 CoGANs。然而，该方法仅在源领域与目标领域非常相似的情况下（如 MNIST 和 USPS）表现出优势，在我们的实验中，当分布差异较大时，难以使其收敛。

接着，我们选择通过解耦权重来允许源域和目标域的独立映射。这种学习范式更加灵活，因为它能够学习到更多领域特定的特征抽取。然而需要注意的是，目标领域无法访问标签，因此如果没有适当的初始化和训练过程，不采用权共享时，目标模型可能会迅速收敛到退化解。因此，我们使用预训练的源模型作为目标表示空间的初始化，并在对抗训练过程中固定源模型。

这样做时，我们实际上是在学习一种非对称映射，即修改目标模型以匹配源分布。这与最初的生成对抗学习情景最为相似，其中生成空间被不断更新，直到其与固定的现实空间无法区分。因此，我们选择上一节中描述的求逆标签 GAN 损失。

因此，我们提出的方法 ADDA 对应如下无约束优化：

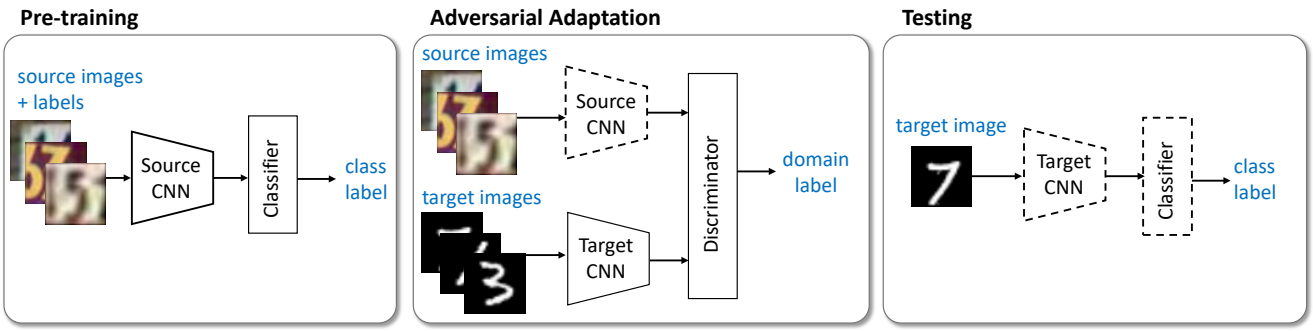

图 3: 我们提出的对抗性判别领域自适应（ADDA）方法的概览。首先，使用标注的源图像样本预训练一个源编码器卷积神经网络。接着，通过学习目标编码器卷积神经网络实现对抗性自适应，使得看到编码后的源域和目标域样本的判别器无法可靠预测其领域标签。在测试阶段，目标图像通过目标编码器映射到共享特征空间，并由源分类器进行分类。虚线表示固定网络参数。

$$
\begin{aligned}
&\min_{M_s,C}\ \mathcal{L}_{\text{cls}}(\mathbf{X}_s, Y_s) = \\
&\qquad -\mathbb{E}_{(\mathbf{x}_s,y_s)\sim(\mathbf{X}_s,Y_s)} \sum_{k=1}^{K} \mathbb{1}_{[k=y_s]} \log C(M_s(\mathbf{x}_s)) \\
&\min_{D}\ \mathcal{L}_{\text{adv}_D}(\mathbf{X}_s, \mathbf{X}_t, M_s, M_t) = \\
&\qquad -\mathbb{E}_{\mathbf{x}_s\sim\mathbf{X}_s}[\log D(M_s(\mathbf{x}_s))] \\
&\qquad\qquad -\mathbb{E}_{\mathbf{x}_t\sim\mathbf{X}_t}[\log(1 - D(M_t(\mathbf{x}_t)))] \\
&\min_{M_s,M_t}\ \mathcal{L}_{\text{adv}_M}(\mathbf{X}_s, \mathbf{X}_t, D) = \\
&\qquad -\mathbb{E}_{\mathbf{x}_t\sim\mathbf{X}_t}[\log D(M_t(\mathbf{x}_t))].
\end{aligned}
\tag{9}
$$

我们选择分阶段优化这一目标。首先，我们通过使用标注的源数据 $\mathbf{X}_s$ 和 Y_s 进行训练，在 M_s 和 C 上优化 $\mathcal{L}_{\text{cls}}$ 。由于我们在学习 M_t 时选择固定 M_s ，因此可以无需重新考虑第一项目标，从而优化 $\mathcal{L}_{\text{adv}_D}$ 和 $\mathcal{L}_{\text{adv}_M}$ 。整个训练过程的总结如图 3 所示。

我们注意到，前一节提出的统一框架使我们能够比较先验领域对抗方法，并就不同的变差因素做出明智决策。通过该框架，我们得以提出一种新颖的领域自适应方法 ADDA，并深入理解我们的设计选择。在下一节中，我们展示了在无监督领域自适应基准任务上的良好结果，研究了数字间以及模态间的自适应问题。

5. 实验

我们现对 ADDA 在四种不同领域偏移下的无监督分类适应能力进行评估。我们研究了三个难度不同的数字数据集：MNIST [18]、USPS 和 SVHN [19]。此外，我们还在 NYUD [20] 数据集上进行评估，以研究跨模态的适应能力。所有实验数据集的示例图像如图 4 所示。

在数字适应的情况下，我们与多种最先进的无监督适应方法进行了比较，这些方法均基于领域对抗学习目标。在我们的 4 种实验设置中，有 3 种情况下，我们的方法优于所有其他竞争方法；在最后一种研究的领域偏移情况下，我们的方法仅略逊于一种竞争方法。

我们还在真实世界中的模态适应任务上验证了我们的模型，使用了 NYU 深度数据集。尽管 RGB 模态与深度模态之间存在较大的领域差异，ADDA 仍能学习到有效的深度表示，且无需任何标注的深度数据，相较于非自适应基准提升了超过 50%（相对）。

5.1. MNIST、USPS 和 SVHN 数字数据集

我们在无监督适应任务中实验验证了所提出的方法，该任务涉及 MNIST [18]、USPS 和 SVHN [19] 数字数据集之间的适应，这些数据集均包含 10 个数字类别。每个数据集的示例图像如图 4 和表 2 所示。在 MNIST 与 USPS 之间的适应任务中，我们遵循文献 [21] 中建立的训练协议，从 MNIST 中采样 2000 张图像，从 USPS 中采样 1800 张图像。在 SVHN 与 MNIST 之间

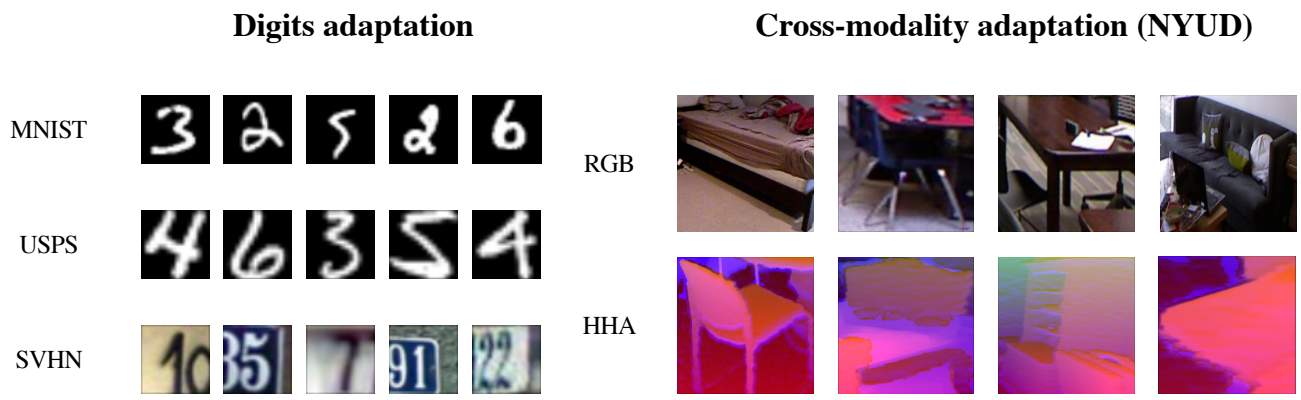

图 4: 我们在两种不同情景下，对无监督跨领域适应的四种领域偏移进行了 ADDA 评估。第一种情景是在 MNIST、USPS 和 SVHN 数据集之间的适应（左）。第二种情景是来自 NYU 深度数据集的 RGB 模态与深度模态之间具有挑战性的跨模态适应任务（右）。

Method	MNIST → USPS	USPS → MNIST	SVHN → MNIST
Source only	0.752 ± 0.016	0.571 ± 0.017	0.601 ± 0.011
Gradient reversal	0.771 ± 0.018	0.730 ± 0.020	0.739 [16]
Domain confusion	0.791 ± 0.005	0.665 ± 0.033	0.681 ± 0.003
CoGAN	0.912 ± 0.008	0.891 ± 0.008	did not converge
ADDA (Ours)	0.894 ± 0.002	0.901 ± 0.008	0.760 ± 0.018

表 2: 在 MNIST、USPS 和 SVHN 之间的无监督适应实验结果。

的适应任务中，为与 [16] 进行对比，我们使用完整的训练集。所有实验均在无监督情景下进行，即目标领域的标签被隐藏，我们考虑三个方向的适应：MNIST→ USPS、USPS→ MNIST 以及 SVHN→ MNIST。

在这些实验中，我们使用了 Caffe 源代码中提供的简单修改版 LeNet 架构 [18, 22]。在使用 ADDA 进行训练时，我们的对抗判别器由 3 个全连接层组成：两个包含 500 个隐藏单元的层，随后是最终的判别器输出。每个 500 单元的层均使用 ReLU 活性值函数。

我们的实验结果如表 2 所示。在较简单的 MNIST 与 USPS 数据集迁移任务中，尽管 ADDA 模型远比当前的最先进模型 CoGANs [13] 简单，但其性能仍可与之相媲美。这提供了有力证据，表明生成图像所需的机制对实现有效适应作用不大。此外，我们在更具挑战性的 SVHN 与 MNIST 任务上与其他方法相比展示了令人信服的结果，表明我们的方法具有泛化到多种情景的潜力。相比之下，我们无法使 CoGANs 在 SVHN 与 MNIST 上收敛——由于这两个领域差异过大，我们无法为它们训练耦合的生成器。

5.2. 模态适应

我们使用 NYU 深度数据集 [20]，该数据集包含 1449 张室内场景图像中 19 个物体类别的边界框标注。数据集被划分为训练集（381 张图像）、验证集（414 张图像）和测试集（654 张图像）。为了进行跨模态适应，我们首先从数据集中裁剪出这 19 个类别实例的紧密边界框，并在物体裁剪图像上评估一个 19 分类任务。为确保同一实例不会同时出现在两个领域中，我们使用训练集中的 RGB 图像作为源领域，验证集中的深度图像作为目标领域。这对应于 2,186 张标注源图像和 2,401 张未标记目标图像。图 4 展示了每个领域的样本。

我们考虑在这些由 RGB 和 HHA 编码的深度图像

	bathtub	bed	bookshelf	box	chair	counter	desk	door	dresser	garbage bin	lamp	monitor	night stand	pillow	sink	sofa	table	television	toilet	**overall**
# of instances	19	96	87	210	611	103	122	129	25	55	144	37	51	276	47	129	210	33	17	2401
Source only	0.000	0.010	0.011	0.124	0.188	0.029	0.041	0.047	0.000	0.000	0.069	0.000	0.039	0.587	0.000	0.008	0.010	0.000	0.000	0.139
ADDA (Ours)	0.000	0.146	0.046	0.229	0.344	0.447	0.025	0.023	0.000	0.018	0.292	0.081	0.020	0.297	0.021	0.116	0.143	0.091	0.000	0.211
Train on target	0.105	0.531	0.494	0.295	0.619	0.573	0.057	0.636	0.120	0.291	0.576	0.189	0.235	0.630	0.362	0.248	0.357	0.303	0.647	0.468

表 3: 在 NYUD [20] 数据集上的自适应结果，使用训练集中的 RGB 图像作为源域，验证集中的深度图像作为目标域。由于目标集存在较大的类别不平衡（如 # 实例所示），我们在此报告每个类别的准确率。总体而言，我们的方法将平均每类别准确率从 13.9% 提升至 21.1%。

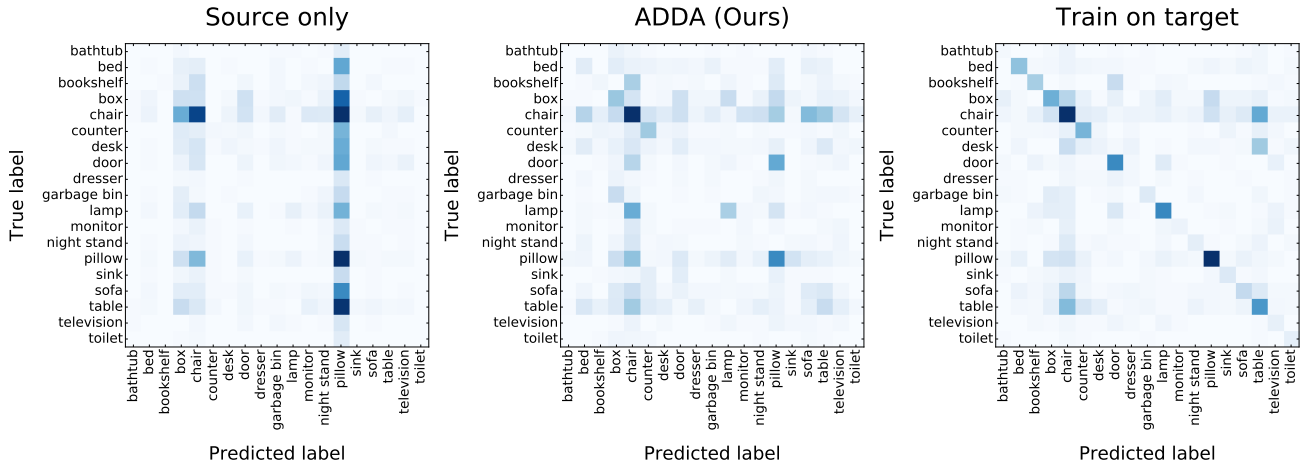

图 5: 源域仅、ADDA 以及基准监督目标模型在 NYUD RGB 到深度适应实验中的混淆矩阵。我们观察到，我们的无监督自适应算法使得 `chair` 这一最常见类别的识别空间更加有利。

之间进行适应 [23]，分别将它们用作源领域和目标领域。由于边界框较为紧密且分辨率相对较低，即使在域内评估时，准确分类也相当困难。此外，该数据集中某些类别的样本数量非常少，例如 `toilet` 和 `bathtub`，这直接导致了分类性能的下降。

在本实验中，我们的基础架构是 VGG-16 架构，其权重初始化为在 ImageNet 上预训练得到的权重 [24]。该网络随后在源领域上进行完全微调，共进行 20,000 次迭代，批量大小为 128。在使用 ADDA 进行训练时，对抗判别器包含三个额外的全连接层：1024 个隐藏单元，2048 个隐藏单元，然后是对抗判别器的输出。除了输出层外，这些额外的全连接层均采用 ReLU 激活函数。之后，ADDA 训练再继续进行 20,000 次迭代，同样使用批量大小为 128。

我们发现，我们的方法 ADDA 显著提升了该任务的分类准确率。对于某些类别，例如 `counter`，分类准确率从仅使用源数据的基准下的 2.9% 提升至适应后的 44.7%。总体而言，所有类别上的平均准确率从 13.9% 显著提升至 21.1%。然而，并非所有类别都得到改善。有三个类别在适应前没有正确标注的目标图像，适应过程无法恢复这些类别的性能。此外，`pillow` 和 `nightstand` 两个类别的性能在适应后反而下降。

为了进一步了解 ADDA 对分类的影响，图 5 展示了适应前、适应后以及在目标标签存在的理想最佳情

形下的混淆矩阵。检查仅使用源域的基准模型的混淆矩阵可知，领域差异非常显著——因此，网络训练条件较差，错误地将大部分数据预测为 `pillow`。这种倾向于输出 `pillow` 的现象也解释了为何源域仅模型在 `pillow` 类上取得了异常高的准确率，尽管其在其他类别上的表现很差。

相比之下，使用 ADDA 训练的分类器预测的类别种类要广泛得多。这导致 `pillow` 类的准确率下降，但其他许多类别的准确率显著提高。此外，与“在目标上训练”的模型相比，ADDA 模型所犯的错误中有很多是合理的，例如 `chair` 和 `table` 类之间的混淆，表明 ADDA 模型在深度图像上学习到了有用的表示。

6. 结论

我们提出了一种基于对抗学习目标的无监督领域自适应技术统一框架。该框架通过一种简化且连贯的视角，帮助我们理解并关联近期提出的各类自适应方法之间的异同。通过这种对比，我们能够把握每种方法的优势与核心思想，并将这些策略融合为一种新的自适应方法——ADDA。

我们对无监督适应方法在四种领域偏移情况下的表现进行了评估。该方法在多种任务上表现出良好的泛化能力，在基准适应数据集以及具有挑战性的跨模态适应任务中均取得了优异结果。额外分析表明，通过 ADDA 学习到的表示与在目标领域使用监督数据学习到的特征更为接近，而非未经适应的特征，这进一步证明 ADDA 能够有效部分消除领域偏移的影响。

参考文献

[1] Jeff Donahue, Yangqing Jia, Oriol Vinyals, Judy Hoffman, Ning Zhang, Eric Tzeng, and Trevor Darrell. Decaf: A deep convolutional activation feature for generic visual recognition. In *International Conference on Machine Learning (ICML)*, pages 647–655, 2014. 1

[2] Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. How transferable are features in deep neural networks? In *Neural Information Processing Systems (NIPS)*, pages 3320–3328, 2014. 1

[3] A. Gretton, AJ. Smola, J. Huang, M. Schmittfull, KM. Borgwardt, and B. Schölkopf. *Covariate shift and local learning by distribution matching*, pages 131–160. MIT Press, Cambridge, MA, USA, 2009. 1, 2

[4] Antonio Torralba and Alexei A. Efros. Unbiased look at dataset bias. In *CVPR'11*, June 2011. 1

[5] Eric Tzeng, Judy Hoffman, Ning Zhang, Kate Saenko, and Trevor Darrell. Deep domain confusion: Maximizing for domain invariance. *CoRR*, abs/1412.3474, 2014. 2

[6] Mingsheng Long and Jianmin Wang. Learning transferable features with deep adaptation networks. *International Conference on Machine Learning (ICML)*, 2015. 2

[7] Baochen Sun, Jiashi Feng, and Kate Saenko. Return of frustratingly easy domain adaptation. In *Thirtieth AAAI Conference on Artificial Intelligence*, 2016. 2

[8] Baochen Sun and Kate Saenko. Deep CORAL: correlation alignment for deep domain adaptation. In *ICCV workshop on Transferring and Adapting Source Knowledge in Computer Vision (TASK-CV)*, 2016. 2

[9] Muhammad Ghifary, W Bastiaan Kleijn, Mengjie Zhang, David Balduzzi, and Wen Li. Deep reconstruction-classification networks for unsupervised domain adaptation. In *European Conference on Computer Vision (ECCV)*, pages 597–613. Springer, 2016. 2

[10] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems 27*. 2014. 2, 5

[11] Yaroslav Ganin and Victor Lempitsky. Unsupervised domain adaptation by backpropagation. In

David Blei and Francis Bach, editors, *Proceedings of the 32nd International Conference on Machine Learning (ICML-15)*, pages 1180–1189. JMLR Workshop and Conference Proceedings, 2015. 2

[12] Eric Tzeng, Judy Hoffman, Trevor Darrell, and Kate Saenko. Simultaneous deep transfer across domains and tasks. In *International Conference in Computer Vision (ICCV)*, 2015. 2, 4, 5

[13] Ming-Yu Liu and Oncel Tuzel. Coupled generative adversarial networks. *CoRR*, abs/1606.07536, 2016. 2, 3, 4, 7

[14] Jeff Donahue, Philipp Krähenbühl, and Trevor Darrell. Adversarial feature learning. *CoRR*, abs/1605.09782, 2016. 3

[15] Mehdi Mirza and Simon Osindero. Conditional generative adversarial nets. *CoRR*, abs/1411.1784, 2014. 3

[16] Yaroslav Ganin, Evgeniya Ustinova, Hana Ajakan, Pascal Germain, Hugo Larochelle, François Laviolette, Mario Marchand, and Victor Lempitsky. Domain-adversarial training of neural networks. *Journal of Machine Learning Research*, 17(59):1–35, 2016. 4, 5, 7

[17] Artem Rozantsev, Mathieu Salzmann, and Pascal Fua. Beyond sharing weights for deep domain adaptation. *CoRR*, abs/1603.06432, 2016. 4

[18] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, November 1998. 6, 7

[19] Yuval Netzer, Tao Wang, Adam Coates, Alessandro Bissacco, Bo Wu, and Andrew Y. Ng. Reading digits in natural images with unsupervised feature learning. In *NIPS Workshop on Deep Learning and Unsupervised Feature Learning 2011*, 2011. 6

[20] Nathan Silberman, Derek Hoiem, Pushmeet Kohli, and Rob Fergus. Indoor segmentation and support inference from rgbd images. In *European Conference on Computer Vision (ECCV)*, 2012. 6, 7, 8

[21] M. Long, J. Wang, G. Ding, J. Sun, and P. S. Yu. Transfer feature learning with joint distribution adaptation. In *2013 IEEE International Conference on Computer Vision*, pages 2200–2207, Dec 2013. 6

[22] Yangqing Jia, Evan Shelhamer, Jeff Donahue, Sergey Karayev, Jonathan Long, Ross Girshick, Sergio Guadarrama, and Trevor Darrell. Caffe: Convolutional architecture for fast feature embedding. *arXiv preprint arXiv:1408.5093*, 2014. 7

[23] Saurabh Gupta, Ross Girshick, Pablo Arbeláez, and Jitendra Malik. Learning rich features from rgb-d images for object detection and segmentation. In *European Conference on Computer Vision (ECCV)*, pages 345–360. Springer, 2014. 8

[24] K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. *CoRR*, abs/1409.1556, 2014. 8